Linux内核源代码导读

中国科学技术大学计算机系
陈香兰（0551－3606864）
xlanchen@ustc.edu.cn

Spring 2009

嵌入式系统实验室

EMBEDDED SYSTEM LABORATORY

SUZHOU INSTITUTE FOR ADVANCED STUDY OF USTC

Ext2文件系统简介

嵌入式系统实验室

EMBEDDED SYSTEM LABORATORY

SUZHOU INSTITUTE FOR ADVANCED STUDY OF USTC

- EXT2文件系统是EXT文件系统的升级，在Linux中得到了广泛的使用。

- 介绍EXT2文件系统的
  - 磁盘组织
  - 目录项和支持的文件类型

Layouts of an Ext2 partition and of an Ext2 block group

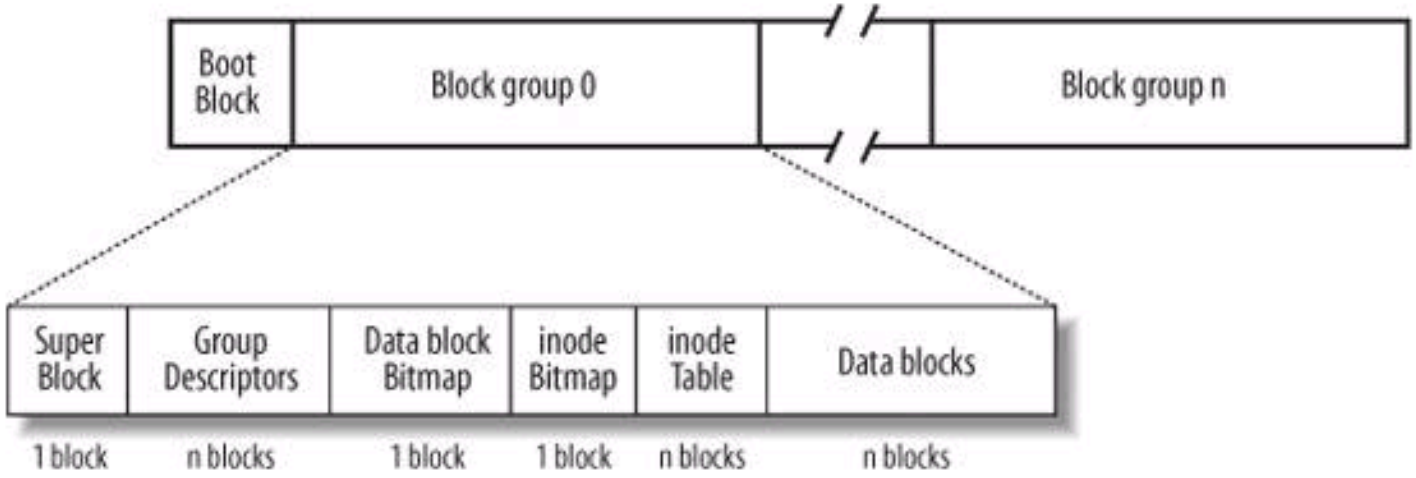

- EXT2磁盘块组中的磁盘块按顺序被组织成：
  - 一个用作**超级块**的磁盘块。
    - 在这个磁盘块里，存放了文件系统超级块的一个拷贝；
  - N个记录**组描述符**的磁盘块；
  - 1个记录**数据块位图**的磁盘块；
  - 1个记录**索引结点位图**的磁盘块；
  - N个用作**索引结点表**的磁盘块；
  - N个用作**数据块**的磁盘块。

冗余，使用块组**0**
e2fsck更新或恢复
块组大小主要受限于块位图

EXT2的超级块

- 每个块组的第一个磁盘块用来保存所在EXT2 fs的超级块
- 多个块组中的超级块形成冗余
  - 在某个或少数几个超级块被破坏时，可用于恢复被破坏的超级块信息。（e2fsck）
- 注意：大多数数据结构存在两个版本
  - 磁盘存储版本，例如ext2_super_block（阅读）
  - 内存版本，例如ext2_sb_info （阅读）

组描述符

- 组描述符用来描述一个磁盘块组的相关信息
- 数据结构为ext2_group_desc（阅读）

索引结点

- EXT2中所有的索引结点大小相同，都是128个字节。
- 数据结构
  - 磁盘存储数据结构ext2_inode（阅读）
  - 内存中结构ext2_inode_info（阅读）
- 理论基础：文件数据块的组织方式
  - 链式（显式 vs 隐式）
  - 索引方式（直接索引，一级索引，二级索引，等等；组合索引）

关于索引节点中的i_block[]

- ext2的索引结点中使用了组合索引方式。

```
00241:      __le32    i_block[EXT2_N_BLOCKS];/* Pointers to blocks */
```

```
00159: /*
00160:  * Constants relative to the data blocks
00161:  */
00162: #define  EXT2_NDIR_BLOCKS        12
00163: #define  EXT2_IND_BLOCK              EXT2_NDIR_BLOCKS
00164: #define  EXT2_DIND_BLOCK             (EXT2_IND_BLOCK + 1)
00165: #define  EXT2_TIND_BLOCK             (EXT2_DIND_BLOCK + 1)
00166: #define  EXT2_N_BLOCKS           (EXT2_TIND_BLOCK + 1)
```

- 前12项用作直接索引
- 第13项用作间接索引
- 第14项用作二次间接索引
- 第15项用作三次间接索引

索引节点表

- EXT2的一个磁盘块组中的索引结点存储在一组连续的磁盘块中，形成一个索引结点表。
- 这组磁盘块中的第一个磁盘块的块号存储在超级块的bg_inode_table数据项中。

- 根据磁盘块的大小，可以计算出每个磁盘块能容纳多少个索引结点
- 根据索引结点的总个数，可以计算出索引结点表所需要占用的磁盘块的个数。

数据块位图和索引结点块位图

- EXT2的空闲盘块分配算法采用了位图法
- 位图：
  便于查找数据块或索引结点的分配信息
- 每个位（bit）都对应了一个磁盘块：
  - 0，表示对应的磁盘块（或索引结点）空闲
  - 1，表示占用。
- 2个位图分别占用一个专门的磁盘块。
- 根据磁盘块的大小，可以计算出每个块组中最多能容纳的数据块个数和索引节点块个数。

（二）EXT2中的目录项和文件类型

- 在EXT2中，目录是一种特殊的文件，这种文件的数据块中存放了该目录下的所有目录项

```
00513: /*
00514:  * Structure of a directory entry
00515:  */
00516: #define EXT2_NAME_LEN 255
00517:
00518: struct ext2_dir_entry {
00519:         __le32  inode;                  /* Inode number */
00520:         __le16  rec_len;        /* Directory entry length */
00521:         __le16  name_len;               /* Name length */
00522:         char name[EXT2_NAME_LEN];       /* File name */
00523: };
```

❖ 新版的目录项结构

```
00525: /*
00526:  * The new version of the directory entry.  Since EXT2 structures are
00527:  * stored in intel byte order, and the name_len field could never be
00528:  * bigger than 255 chars, it's safe to reclaim the extra byte for the
00529:  * file_type field.
00530:  */
00531: struct ext2_dir_entry_2 {
00532:         __le32  inode;                  /* Inode number */
00533:         __le16  rec_len;        /* Directory entry length */
00534:         __u8    name_len;               /* Name length */
00535:         __u8    file_type;
00536:         char name[EXT2_NAME_LEN];       /* File name */
00537: };
```

EXT2支持的文件类型

- EXT2在目录项中存放了文件的类型信息。文件类型可以是0～7中的任意一个整数。它们分别代表如下含义：
  - 0：文件类型未知；
  - 1：普通文件类型；
  - 2：目录；
  - 3：字符设备；
  - 4：块设备；
  - 5：有名管道FIFO；
  - 6：套接字；
  - 7：符号链接。

```
/*
 * Ext2 directory file types.  Only the low 3 bits are used.  The
 * other bits are reserved for now.
 */
enum {
        EXT2_FT_UNKNOWN,
        EXT2_FT_REG_FILE,
        EXT2_FT_DIR,
        EXT2_FT_CHRDEV,
        EXT2_FT_BLKDEV,
        EXT2_FT_FIFO,
        EXT2_FT_SOCK,
        EXT2_FT_SYMLINK,
        EXT2_FT_MAX
};
```

注意:

Type	Disk data structure	Memory data structure	Caching mode
Superblock	ext2_super_block	ext2_sb_info	Always cached
Group descriptor	ext2_group_desc	ext2_group_desc	Always cached
Block bitmap	Bit array in block	Bit array in buffer	Dynamic
inode bitmap	Bit array in block	Bit array in buffer	Dynamic
inode	ext2_inode	ext2_inode_info	Dynamic
Data block	Array of bytes	VFS buffer	Dynamic
Free inode	ext2_inode	None	Never
Free block	Array of bytes	None	Never

（三）创建一个ext2文件系统

- 在磁盘上创建文件系统通常有两个步骤：
  - 格式化磁盘
    - Linux中：superformat或者fdformat
  - 创建文件系统
    - Ext2：mke2fs
- mke2fs的缺省参数
  - 磁盘块大小：1024字节
  - 分片：目前不支持，因此与磁盘块一样
  - 分配inode的个数：1/8192B
  - 永久保留的块的个数：5%

创建流程

1. 初始化超级块和组描述符
2. Optionally, 检查是否有坏块，若有创建坏块列表
3. 对每个块组，保留所有用来存放超级块、组描述符、inode表、2个位图的磁盘块
4. 初始化每个块组中的位图
5. 初始化每个块组中的inode表
6. 创建 */root* 目录
7. 创建 *lost+found* 目录（供*e2fsck* 使用，与坏块相关）
8. 为上述两个目录而更新位图信息
9. 若有坏块，则将其在 *lost+found* 目录中组织起来

以1.44MB的软盘为例，创建ext2文件系统后

Block	Content
0	Boot block
1	Superblock
2	Block containing a single block group descriptor
3	Data block bitmap
4	inode bitmap
5-27	inode table: inodes up to 10: reserved (inode 2 is the root); inode 11: *lost+found*; inodes 12-184: free
28	Root directory (includes ., .., and *lost+found*)
29	*lost+found* directory (includes . and ..)
30-40	Reserved blocks preallocated for *lost+found* directory
41-1439	Free blocks

（四）Ext2提供的各种对象方法

- 超级块对象方法

```
00150: static struct super_operations ext2_sops = {
00151:         read_inode:     ext2_read_inode,
00152:         write_inode:    ext2_write_inode,
00153:         put_inode:      ext2_put_inode,
00154:         delete_inode:   ext2_delete_inode,
00155:         put_super:      ext2_put_super,
00156:         write_super:    ext2_write_super,
00157:         statfs:         ext2_statfs,
00158:         remount_fs:     ext2_remount,
00159: };
```

❖ 索引节点对象方法

```
00052: struct inode_operations ext2_file_inode_operations = {
00053:     truncate:    ext2_truncate,
00054: };
```

```
00338: struct inode_operations ext2_dir_inode_operations = {
00339:     create:         ext2_create,
00340:     lookup:         ext2_lookup,
00341:     link:       ext2_link,
00342:     unlink:         ext2_unlink,
00343:     symlink: ext2_symlink,
00344:     mkdir:          ext2_mkdir,
00345:     rmdir:          ext2_rmdir,
00346:     mknod:          ext2_mknod,
00347:     rename:         ext2_rename,
00348: };
```

```
00035: struct inode_operations ext2_fast_symlink_inode_operations = {
00036:     readlink:  ext2_readlink,
00037:     follow_link:  ext2_follow_link,
00038: };
```

❖ 文件对象方法

```
00037: /*
00038:  * We have mostly NULL's here: the current defaults are ok for
00039:  * the ext2 filesystem.
00040:  */
00041: struct file_operations ext2_file_operations = {
00042:         llseek:         generic_file_llseek,
00043:         read:           generic_file_read,
00044:         write:          generic_file_write,
00045:         ioctl:          ext2_ioctl,
00046:         mmap:           generic_file_mmap,
00047:         open:           generic_file_open,
00048:         release: ext2_release_file,
00049:         fsync:          ext2_sync_file,
00050: };
```

```
00591: struct file_operations ext2_dir_operations = {
00592:         read:           generic_read_dir,
00593:         readdir:   ext2_readdir,
00594:         ioctl:          ext2_ioctl,
00595:         fsync:          ext2_sync_file,
00596: };
```

（五）管理ext2的磁盘空间

- 存储在磁盘上的文件与用户所“看到”的文件有所不同：
  - 用户感觉，文件在逻辑上是连续的
  - 而在磁盘上，存储文件数据的磁盘块可能分散在磁盘各处
  - 用户感觉，文件可能比较大
  - 而在磁盘上，由于文件空洞的存在，分配给文件的磁盘空间可能小于用户感觉到的文件大小。

- 涉及到如下操作:
  - 创建/删除一个索引节点
  - 数据块的寻址
  - 文件空洞
  - 分配/释放一个数据块

创建/删除一个索引节点

- 创建一个磁盘索引节点

```
00314: struct inode * ext2_new_inode (const struct inode * dir, int mode)
```

- 删除一个索引节点

```
00133: /*
00134:  * NOTE!  When we get the inode, we're the only people
00135:  * that have access to it, and as such there are no
00136:  * race conditions we have to worry about. The inode
00137:  * is not on the hash-lists, and it cannot be reached
00138:  * through the filesystem because the directory entry
00139:  * has been deleted earlier.
00140:  *
00141:  * HOWEVER: we must make sure that we get no aliases,
00142:  * which means that we have to call "clear_inode()"
00143:  * _before_ we mark the inode not in use in the inode
00144:  * bitmaps. Otherwise a newly created file might use
00145:  * the same inode number (not actually the same pointer
00146:  * though), and then we'd have two inodes sharing the
00147:  * same inode number and space on the harddisk.
00148:  */
00149: void ext2_free_inode (struct inode * inode)
```

关于数据块的寻址

- 任何一个常规文件都会包含一系列数据块
- 文件内块号 vs. 逻辑块号
  - 根据数据在文件中的偏移可以计算逻辑块号：
    - 首先计算出文件内块号 =（偏移f－1）/块大小的商 ＋1
    - 根据索引信息，查询到逻辑块号

混合索引示意图

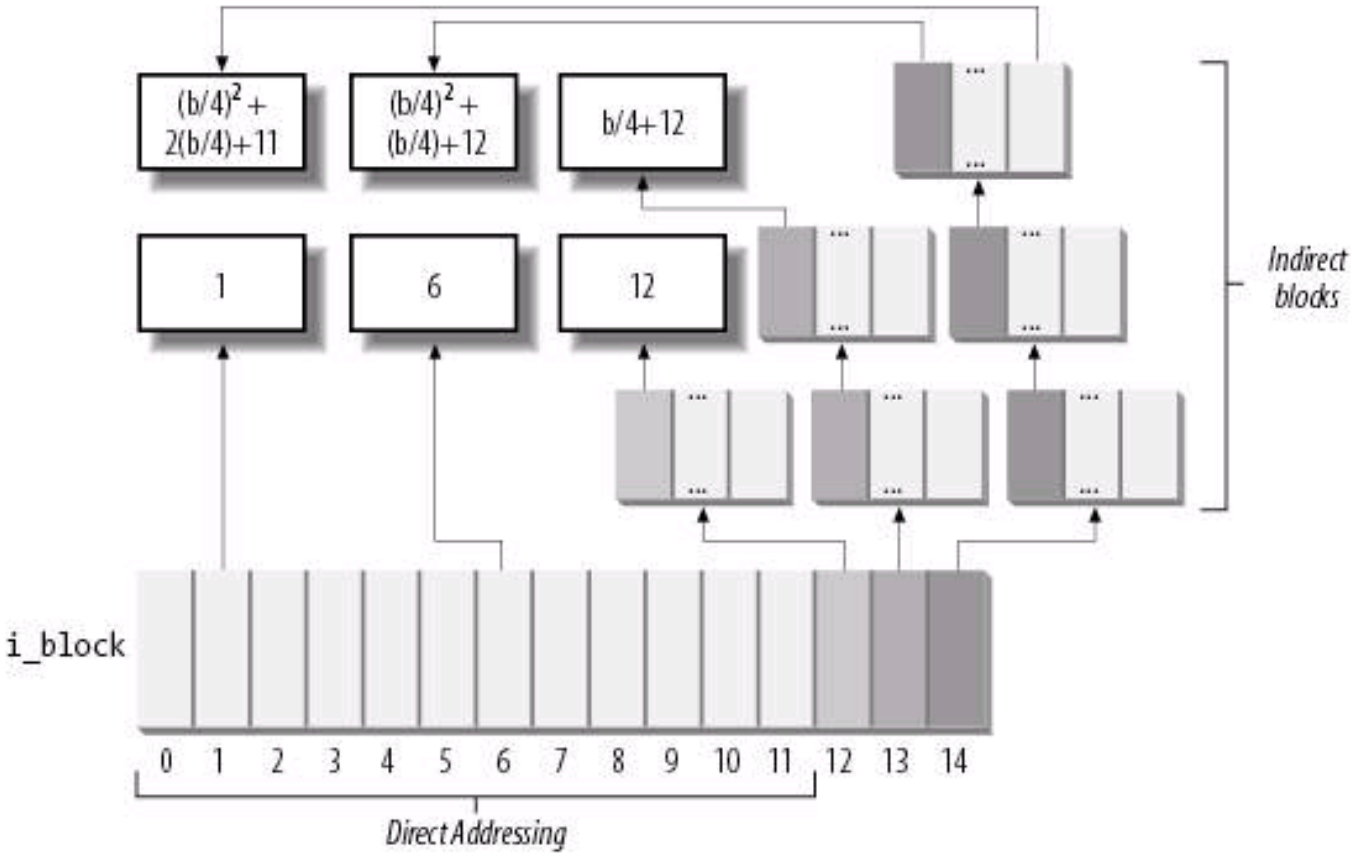

文件大小限制

Block size	Direct	1-Indirect	2-Indirect	3-Indirect
1,024	12 KB	268 KB	64.26 MB	16.06 GB
2,048	24 KB	1.02 MB	513.02 MB	256.5 GB
4,096	48 KB	4.04 MB	4 GB	~ 4 TB

关于文件空洞

- A **file hole** is a portion of a regular file that contains null characters and is **not stored in any data block** on disk.
- 这是UNIX文件一直以来都有的一个特性

- 例如命令：

```
$ echo -n "X" | dd of=/tmp/hole bs=1024 seek=6
```

创建一个大小为1024×6 + 1字节的文件，这个文件有一个1024×6 = 6144个字节大小的空洞。只有最后一个字节存放了字母“X”

- 文件空洞可以节省磁盘空间
- Ext2通过数据块的动态分配来实现这一点：
  当且仅当一个进程要写数据到文件中的时候才真正分配磁盘块

分配/释放一个数据块

- 当一个文件需要新的数据块来存放数据时

```
00494: /*
00495:  * Allocation strategy is simple: if we have to allocate something, we will
00496:  * have to go the whole way to leaf. So let's do it before attaching anything
00497:  * to tree, set linkage between the newborn blocks, write them if sync is
00498:  * required, recheck the path, free and repeat if check fails, otherwise
00499:  * set the last missing link (that will protect us from any truncate-generated
00500:  * removals - all blocks on the path are immune now) and possibly force the
00501:  * write on the parent block.
00502:  * That has a nice additional property: no special recovery from the failed
00503:  * allocations is needed - we simply release blocks and do not touch anything
00504:  * reachable from inode.
00505:  */
00506:
00507: static int ext2_get_block(struct inode *inode, long iblock, struct buffer_head *bh_result, int create)
```

- 当一个文件被删除或者被截断时

```
00788: void ext2_truncate (struct inode * inode)
```

↓

```
00753: static void ext2_free_branches(struct inode *inode, u32 *p, u32 *q, int depth)
```

↓

```
00250: /* Free given blocks, update quota and i_blocks field */
00251: void ext2_free_blocks (struct inode * inode, unsigned long block,
00252:                        unsigned long count)
```

Thanks!

The end.

嵌入式系统实验室

EMBEDDED SYSTEM LABORATORY

SUZHOU INSTITUTE FOR ADVANCED STUDY OF USTC